Google IO Extended 2025杭州站分享

Topic1: 2天10w+用户 Flowith Neo做对了什么?

Speaker: Flowith CMO

Creation 1.0: 基于不同文件格式的创造活动

Flowith: 公司24年8月上线，Creation 2.0, 一个月前上线Flowith, 无限步骤、无限上下文、无限工具

未来动态：

- 太监agent
- dozer: 语音agent.可以听8小时的语音，之前的语音agent都是会议管理，但核心问题不是记录，而是任务如何分发

一些观点：

- 现在chatbot的问题：每次单独上传文件，没有记忆
- What is AI Native? -> AI Native is Human Native
- AI PPT的问题：5年之后是否还需要PPT?
- Vibe coding: 人也应该是进入类似于drunk状态，做一些平时不可能去做的事情
- 现在的agent更强调智能，而更重要的是agency，主动性比智力更重要（模型会做奥数题，然后呢，能给生活带来什么改变？）
- why rag? LLM本身不会包含私有内容
- 为什么需要无限步骤？类比真人：人类写论文，不是一次完成的，而是分阶段，分模块完成，agent也可以按照这种方式来实现
- AI能写出很好的东西，是人牛逼，而不是AI牛逼（同样的输入框，不同的结果，还是用户设计prompt的能力强）
- A没有幻觉，是人类的幻觉，人类没有把问题描述清楚
- System prompt 不要作太多事情，否则模型过几个一更新，很多内容都的重新做
- AI没有技术壁垒，AI的壁垒是速度和想法上，用户数据也会成为壁垒，存在迁移的原因
- agent的特点：底层模型有多个，而模型厂商只用自己的，所以模型厂商并不一定能做到最好（因为他们可能不会用效果更好的友商的模型)
- 模型大厂不赚钱，他们会碰应用层，所以需要猜他们会做哪块，不会做哪块
- 产品需要做到头部
- 壁垒：技术栈、work flow、用户、创新

- 要理性，狠人、不要招太多人，人不是壁垒，
- 需要把pmf跑通

思考和疑问哦：

- Q1: LLM的成本真的会降至零吗?
- Q2: 会做基础模型吗，基础模型厂商也会做agent，会不会有危机感？ DeepSearch, Claude Code等，如何看待基础厂商模型做应用、做agent的情况
- Q3: 大厂与创业公司如何竞争？如何与基础厂商的同类产品对比?

Topic2: Gemini Vertex AI & Multi-Modalities in I/O 2025

Speaker:郑炜 GDE (ML)

Gemini 2.5 Pro还是很强的， e.g.,单元测试分开跑没问题，一起跑就有一个报错？别的模型解决不了，但Gemini2.5 Pro定位出了问题，原始是一个测试有cache，一起跑时影响了别的单测case

Gemini 一些已经和未来会推出的新特性：

- Gemini Deep Think: 推出不同假设，并行地验证每一个假设
- Gemini Stream
- Project Astra
- Proactive audio-> 去除旁边人说话的影响
- native image 输出
- mcp sdk支持
- Gemini diffusion：不是一个Token一个Token输出，而是同时输出一块，全新的方案

Gemma

- 新推出的Gemma 3n，4B大笑，里面套着2B模型，端侧部署时选定用2b还是4b
- 网络结构：matformer
- 训练时：有2-4-8b，每个都是包含在大一级的里面的，训练时随机选择1个权重，所有情况都会训练到
- 优势：类比渲染中的LOD，根据实际情况选择最佳的参数量

Imagen4:

- 图片生成，细节更多，e.g., 生成羽毛的细节
- 导出时自动upsample
- ;能生成更真实的文字

Lyria2:

- 乐谱生成
- 安全问题，暂不支持生成人声
- E.g., 生成爵士乐

Veo3:

- 8秒左右的视频（API即可可使用），
- 更符合物理逻辑
- 能够合成声音
- 包含Fast 和 quality两种模式; fast绑定信用卡即可使用；
- E.g., 老人与海的视频，英式accent生成Water的发音
- 与Sora效果对比：通过Nerf 3D重建方式，验证两者哪一个更符合物理规律(Veo3更好）
- E.g., 圣诞节视频，2分多钟视频花费350+$

Demo: 实时视频流对话

- 响应时间很快
- 有时候不能说中文（用英文说I Can Speak Chinese)
- 中文、英文音色自然
- 视频分成片段给到模型

我的思考和疑问：

- Q1： gemma 3n能否做到自动选择用2b还是4b的模型?
- Q2: 2-4-8B参数，训练时loss是如何选择的，2-4-8各一个loss吗，
- Q3: 未来能够支持随机选择，是不是说每个层都有可能做成输出?
- Q4: google 的技术路线问题，闭源用gemini, 开源用gemma，两套路线模型不同，而大部分模型开源和商用是一套模型，谷歌这么设计的目的是什么，有什么优势吗，
- 未来Gemini flash版本会用到端侧吗，因为现在的Gemma 4B版本效果跟7B/8B/14BB的模型还是没法比的
- Q5: Imagen4 是否跟Gemini 2.5 里面的生图是同一个模型?

Topic3: 一日不见刮目相看： Web AI 最新进化态

Speaker: 钱俊颖Jax, GDE(Web)

I/O大会的一个Slogan: “Powerful Web made easier”

Speaker观点：AI时代，切图仔会不会消亡：因为门槛降低，所以会有更多人进入这个方向，这个方向就会越繁荣

Web AI是什么？本地Web上跑的AI
框架：

- AI = Cloud AI + Client-side AI
- Web AI 属于Client-side AI
- Web AI包含Buit-in AI(模型自带在浏览器中)

Built-in AI ：

- 谷歌发起的一套标准，目前还在内部测试和试用阶段
- 整体流程：Proposal-> Early Preview Program -> Origin Trials -> Stable（进chrome，默认开启） -> Web Standard
- Built-in AI 的API:
  - Language Detector->支持多少语言?
  - Translator
  - Summarizer/Writer/Rewriter
  - Prompt API，支持多模态， Gemini Nano，全系列支持多模态
  - 结构化输出->json/object,
  - Proofreader: 错误检查（语法，标点错误）
- Built-in AI近半年更新：
  - 参见PPT
- 别的公司的支持：Edge Canary 增加Built-in AI的支持， 内置Phi-4-mini, 因为Gemini Nano本身非开源模型

Gemmaverse Web：

- 非浏览器集成，开发者自己load模型
- 手动load gemma 3/3n, n代表nano，轻量模型
- Mediapipe Tasks支持
- MediaPipe Solutions
- 哪里找模型？hf上支持Transformers.js， Kaggle，LiteRT 社区(Lite Runtime), 前身是TensorFlowLite
- 端侧特点：很多模型缓存（浏览器缓存，文件缓存，indexedDB API)
- Hybrid模式：云端+设备端，e.g., firebase自动支持云端和端侧，端侧不能完成任务时再用云端

思考和疑问：

- Q1：浏览器模型能做什么？ -> Rewrite, Prompt,

- Q2: built-in AI的定位是什么？是类似Apple Intellgency 那样，本地网页的文本改写？翻译？场景有点受限了？API未来和拓展吗？例如增加图像生成等
- Q3: 只有JS的API吗?
- Q3: Gemini Nano
- Q4: Chromium是开源的，那gemini nano在其中不开源吗
- Q5: 最终，built-in AI在手机上能用到吗，是否需要WebGPU支持
- Q6: Task 格式能否支持从hf上的模型转换？格式是否开源?
- Q7: 端云融合模式，怎么确定端侧模型不能满足需求?
- Q8: 浏览器拓展？是拓展开发中可以用吗?

Topics4:

Speaker: 施德来 @DemoWay

施德来和DemoWay：

- 施德来曾经在网易、阿里等大厂就职，目前创业创办DemoWay
- DemoWay: 3个正式员工，有盈利项目

DemoWay主要产品迭代历史

1. 互动Demo；录屏操作，然后展示每个流程
2. HTML To Sigma
3. HTML To Pixso
4. HTML To AI（MCP 使用门槛有点高，HTML to AI降低使用门槛）
5. DemoWay近期开源

为什么复用现有的技术?

- 复用现有的优势（互动Demo是SLG，流程太长）借助平台流量
- 自增长
- 反过来增强现有产品
- 给现有产品带来客户
- 填补国内空白

干货：

- 基础设施越来越丰富，以后有越来越多做出世界级产品的小公司（4人一下）
- 从自己擅长的事情出发+AI，很多事情做的很好
- qumei: 海外产品有些其实比较差，核心是做的比较早
- 做PLG是SLG?

- 核心长板是真的足够长
- 只会做一个事情，只会动嘴，减分
- 会吹牛

海外

- Day1就面向全球，同一套代码，国内外一样，支付、登录不同而已
- 独立域名、服务器、配套运营（邮件）一开始就分开->跟客户在同一个场域（google sheet, slack->feishu)
- 老外也是人，也很希望贴身服务，也希望便宜一点，中国客户想用的他们也想用
- 海外支付很落后，tips: 没有付款渠道，可以用打赏模式
- 客户公司有防火墙，详尽的说明，让他们去开白名单
- 版权问题：千禧年数字版权法，引起重视，不能服软，

用了不会错的工具：
海外：

- discord; 用户群
- cloudfare
- slack
- Metabase
- Directs
  国内：
- 珍视国内用户的价值
- 代码可以先在国内上线
- 不管国内外，用户需求都是相近的
- 如果用户不付费，也不反馈问题，则用户几乎毫无价值->加企业微信

其他：

- 低价竞争不是好策略，会付费的用户反正会付费
- 不会付费的聊再多也不会付费
- 让用户写用户案例，送会员，送钱
- 付钱的不是使用者，需要把相关流程走顺（e.g., 公司IT付费，个人使用，联系领导付费等）

动手实践1：Gemma3 端侧部署

Mentor: 陈瑜 GDE (ML)

流程：

1. Mac/Windows安装Android Studio
2. Android Studio打开Google AI Edge Gallery工程并build
3. 连接真机，运行工程
4. HF上下载模型，adb push到真机
5. 真机运行Google AI Edge Gallery App，支持

Gemma框架:

- 2个头，一个image，一个text
- 蒸馏了Gemini，比微调效果好

Google AI Edge:

- 支持iOS/android/Web的端侧运行框架，目前还不支持iOS
- ask文件: 包含模型权重和+ tokenizer
- RTLite: 现在支持PyTorch, Jax和Tensorflow模型的转换了
- 端侧的应用场景：
  - 私有数据
  - 垂类行业，用户的输入很聚焦，因此小模型+agent，其实效果更好
    - E.g., 车管所换证，”我在杭州，我的驾照是温州的，如何操作“->识别出异地换证、xx、xx等，4个小的agent

动手实践2：Gemini 2.5 Pro 分析Option数据

Mentor: 王玉成 GDE (ML & IoT)

操作材料地址：

1. https://codelabs.developers.google.com/codelabs/intro-gemini-25-pro-colab#0
2. https://github.com/YuchengWang/OptionAnalyze/blob/main/option_analyze_using_gemini_2.5_pro.ipynb